

EOS-MAS: Export Order-to-Shipment Multi-Agent System


Sistem multi-agen cerdas untuk manufaktur furnitur berorientasi ekspor

Laporan Progres Tugas 1

Agentic Enterprise (AI Agentic Technology Systems for Digital Enterprise Ecosystem) - Magister AI

Penyusun: [Isi nama Anda] ([Isi NIM]) - pengerjaan individu

Repositori kode: <https://github.com/AdityaIKO/Agentic-Enterprise>



Daftar Isi

Daftar Isi	2
Ringkasan Eksekutif	4
Peta Jawaban Tugas 1	4
1. Peran Anggota Tim	5
2. Deskripsi Problem	5
2.1 Konteks dan pernyataan masalah	5
2.2 Klasifikasi lingkungan (Tabel 2.1 Bab 2)	6
2.3 PEAS	6
2.4 KPI dan posisi terhadap solusi yang ada	6
3. Ilustrasi Data dan Perhitungan Komputasi	7
3.1 Contoh data	7
3.2 Perhitungan manual yang dapat diperiksa	7
3.3 Simulasi penuh	8
4. Rumus Notasi Matematika dan Arti Simbol	10
A. Agen dan sistem multi-agen	10
B. Model masalah ekspor	10
C. Penjadwalan produksi (Contract Net)	10
D. Keputusan carrier (hibrida ML + DSS)	10
E. Machine learning	11
F. Reinforcement learning	12
G. Koordinasi dan negosiasi	12
H. Keamanan, trust, dan mobilitas agen	12
5. Tiga Penelitian Serupa (Topik Order-to-Shipment Ekspor)	12
6. Intelligent Agent System	13
6.1 Mengapa multi-agent, bukan single agent?	13
6.2 Tiga penelitian yang memakai agen cerdas	14
6.3 Diagram rencana sistem	15
6.4 Agen dan komponen internal	16
6.5 Komunikasi, keamanan, dan trust	17
6.6 Metode AI / ML / DL / RL dan alasan pemilihan	17
6.7 Tingkat otonomi dan governance	17
6.8 Mobile agent (Scout)	18
7. Implementasi dan Eksperimen	19
7.1 Rancangan eksperimen	19
7.2 Hasil utama	19
7.3 Ablation: kontribusi tiap komponen	19
7.4 Ketahanan dan skala	20
7.5 Model ML dan RL	21

7.6 Ancaman validitas dan keterbatasan	22
8. Kesimpulan dan Rencana Berikutnya	22
Peta materi kuliah ke implementasi	23
Referensi	23
Repositori dan cara menjalankan	23

Ringkasan Eksekutif

Eksportir manufaktur harus menyelesaikan produksi, dokumen ekspor, dan pengiriman ke gerbang pelabuhan sebelum closing kapal. Satu gangguan kecil (mesin rusak, kode HS keliru, kargo tidak terangkut/roll-over) menggeser pengiriman minimal 7 hari, memicu penalti, biaya penyimpanan, dan risiko L/C kedaluwarsa.

EOS-MAS adalah sistem multi-agen cerdas untuk masalah ini: agen order, mesin, compliance, risk, learning, carrier, agen governance, dan satu Scout Agent bergerak (mobile). Agen bernegosiasi lewat Contract Net Protocol, memakai kombinasi ML klasik + aturan + DSS + Q-learning, dan beroperasi pada tingkat otonomi terkendali dengan persetujuan manusia untuk keputusan berdampak tinggi.

Hasil simulasi (300 skenario berpasangan, 12 order per skenario): pengiriman tepat waktu naik dari 63,9% (proses manual/FIFO) menjadi 87,6%; biaya per order turun dari \$5.082 menjadi \$4.177 (18%); sentuhan manusia per order turun dari 6,0 menjadi 0,56; kesalahan kode HS dari 8,0% menjadi 2,2%.

Temuan yang jujur: (1) agen tunggal berinti terpusat dan multi-agen menghasilkan kualitas keputusan yang sama pada skala kecil karena memakai aturan yang sama; keunggulan multi-agen ada pada ketahanan terhadap kegagalan koordinator (87,3% vs 85,5% tepat waktu saat gangguan pada 50% skenario), beban puncak node (7,7x lebih ringan pada 240 order) dan batas organisasi (carrier, bea cukai). (2) Ada trade-off biaya vs layanan pada pemilihan carrier. (3) Policy RL yang dilatih pada lingkungan abstrak tidak transfer ke simulator penuh; melatih langsung di simulator memberi policy setara aturan yang dituning. (4) Semua data bersifat sintesis dan parameter biaya adalah asumsi; angka ini membuktikan sistem berfungsi dan dapat dibandingkan, bukan performa perusahaan nyata.

Metrik (300 skenario)	Statis	Agen tunggal	Multi-agen
Tepat waktu	63,9%	87,6%	87,6%
Biaya per order	\$5.082	\$4.177	\$4.177
Sentuhan manusia per order	6,00	0,56	0,56
Kesalahan kode HS	8,0%	2,2%	2,2%

Peta Jawaban Tugas 1

Instruksi Tugas 1	Jawaban	Lokasi
Gunakan topik yang dipilih	Topik: EOS-MAS, order-to-shipment ekspor manufaktur (belum diambil kelompok 1-6)	Bagian 2.1
Upload laporan progres	Dokumen ini (PDF) + slide (PPTX) + kode GitHub	-
Peran anggota tim	Pengerjaan individu: seluruh peran dipegang satu orang	Bagian 1
Deskripsi problem	Masalah order-to-shipment, KPI, klasifikasi lingkungan, PEAS	Bagian 2
Ilustrasi data dan perhitungan komputasi	Data sintetis, 11 contoh hitung manual, simulasi penuh	Bagian 3
Rumus notasi dan arti simbol	29 rumus dikelompokkan A-H, tiap simbol dijelaskan	Bagian 4
Tiga penelitian topik serupa	Hathikal 2020; Lee 2024; Ouelhadj & Petrovic 2009	Bagian 5
Mengapa single vs multi-agent	Kriteria Bab 4 + bukti eksperimen (ketahanan, skala, batas organisasi)	Bagian 6.1
Tiga penelitian agen cerdas	Smith 1980; Leita0 2009; Zhao 2024	Bagian 6.2
Diagram rencana sistem	Arsitektur, Contract Net, siklus BDI, Gantt	Bagian 6.3
Komponen internal tiap agen	Tabel 8 agen: BDI, komponen, I/O, metode, otonomi	Bagian 6.4
AI / ML / DL dan alasannya	Portofolio metode + alasan tidak memakai DL/LLM	Bagian 6.6

1. Peran Anggota Tim

Peran (template Project #1)	Tanggung jawab
Leader / product owner	Memilih topik, merumuskan masalah dan KPI, menetapkan lingkup Tugas 1.
Researcher	Studi literatur (3 + 3 penelitian), memetakan materi Bab 1-5 ke desain sistem.
Programmer	Simulator, agen, model ML/RL, lapisan pesan aman, 20 unit test.
Designer	Arsitektur sistem, protokol Contract Net, diagram, dan visualisasi hasil.
Evaluator	Desain eksperimen berpasangan, ablation, uji ketahanan dan skala, catatan validitas.
Presenter	Menyusun laporan PDF dan slide PPT.

Pengerjaan ini individu karena penulis bergabung terlambat ke kelas, sehingga enam peran pada template Project #1 (Leader, Researcher, Programmer, Designer, Evaluator, Presenter) dipegang satu orang. Claude Code dipakai sebagai asisten penulisan kode dan dokumen; keputusan desain, angka, dan klaim ditinjau oleh penulis.

2. Deskripsi Problem


2.1 Konteks dan pernyataan masalah

Sebuah manufaktur furnitur kayu (fiktif) mengekspor 12 order per periode ke beberapa negara tujuan. Setiap order melewati tiga stasiun kerja (pemotongan, perakitan, finishing), menyiapkan dokumen ekspor (klasifikasi HS, invoice, packing list, sertifikat asal/legalitas), lalu dikirim ke pelabuhan dan diberangkatkan dengan kapal milik carrier yang berlayar mingguan. Kargo harus tiba di gerbang pelabuhan sebelum closing kapal; melewatkannya berarti menunggu kapal berikutnya (+7 hari).

Titik nyeri: (1) jadwal produksi tidak mengikuti tenggat closing kapal; (2) mesin rusak tak terduga (laju 0,035 per mesin per hari); (3) dokumen dan kode HS disiapkan setelah produksi selesai dan rawan salah; (4) pemilihan carrier menyeimbangkan biaya vs risiko roll-over yang bergantung kongesti pelabuhan dan musim puncak; (5) informasi tersebar pada organisasi berbeda (pabrik, carrier, bea cukai) sehingga visibilitas silo.

Dampak bisnis: penalti 0,4% nilai order per hari terlambat, demurrage/storage 45 USD per hari, dan diskon 5% jika L/C basi (>10 hari). Pada simulasi, proses manual hanya mengirim 63,9% order tepat waktu dengan rata-rata keterlambatan 2,1 hari.

Pernyataan masalah formal: pada horizon satu periode, pilih jadwal produksi, keputusan dokumen, carrier, dan tindakan pemulihan (lembur/air freight) yang meminimalkan $J = \text{biaya freight} + \text{penyimpanan} + \text{lembur} + \text{sentuhan manusia} + \text{penalti keterlambatan}$, dengan constraint kapasitas mesin, closing kapal, kebijakan compliance, dan batas wewenang agen.



Gambar 1. Contoh nyata (skenario 7): jadwal 4 order pada proses statis vs multi-agen. Dokumen (garis hijau) selesai paralel pada multi-agen; segitiga = closing yang dijanjikan.

2.2 Klasifikasi lingkungan (Tabel 2.1 Bab 2)

Karakteristik	Klasifikasi	Bukti pada kasus ini
Observability	Partially observable	Keandalan carrier, kongesti pelabuhan, dan waktu rusak mesin tidak diketahui pasti sebelumnya
Outcome	Stochastic	Kerusakan mesin (Poisson), roll-over kargo (Bernoulli dengan logit), dokumen kurang (6%)
Change	Dynamic	Jadwal kapal mingguan, indeks kongesti berubah harian, musim puncak mulai di tengah horizon
Actors	Multi-agent	Pabrik, tiga carrier, bea cukai/pelabuhan, pembeli: pemilik dan kepentingan berbeda

Lingkungan yang partially observable, stochastic, dynamic, dan multi-actor menuntut memori, penalaran probabilistik, perencanaan, koordinasi, dan pembelajaran (Bab 2); ini menjadi dasar memilih sistem agen cerdas.

2.3 PEAS

Komponen	Deskripsi EOS-MAS
Performance	Persentase order tepat waktu ($\leq$ LSD); biaya total J per order; rata-rata hari terlambat; tingkat kesalahan HS; jumlah sentuhan manusia; ketahanan (perubahan kinerja saat gangguan); beban node puncak
Environment	Pabrik 3 stasiun x 2 mesin; proses dokumen ekspor dan bea cukai; 3 carrier dengan jadwal kapal mingguan; pelabuhan (kongesti, musim puncak); pembeli dengan LSD
Actuators	Dispatch operasi ke mesin; lembur; booking carrier atau air freight; penerbitan dokumen; eskalasi ke manusia; konfirmasi/penolakan pesan
Sensors	ERP/MES (order, routing); sensor kesehatan mesin (percept sequence); jadwal kapal via Scout Agent; indeks kongesti; umpan balik hasil pengiriman

2.4 KPI dan posisi terhadap solusi yang ada

Vektor KPI sistem (Bab 4): $K = [\text{latensi, throughput, biaya, ketahanan, utilitas, trust}]$. Pada EOS-MAS: latensi keputusan diukur lewat waktu komunikasi, throughput lewat makespan, biaya lewat J, ketahanan lewat perubahan kinerja saat gangguan, utilitas lewat skor hibrida, dan trust lewat trust carrier.

Posisi terhadap solusi yang ada (ringkasan kategori, bukan evaluasi produk): suite ERP/APS, TMS, dan Global Trade Management (mis. SAP GTS, Oracle GTM) unggul pada data master, kepatuhan, dan

integrasi transaksi, tetapi umumnya berbasis aturan/batch, terpisah per modul, dan tidak menegosiasikan keputusan lintas organisasi secara otonom. EOS-MAS tidak menggantikannya; ia menjadi lapisan keputusan agentik di atasnya: menegosiasikan penjadwalan dan carrier, menjaga dokumen paralel dengan produksi, dan mengeskalasi ke manusia sesuai tingkat otonomi.

3. Ilustrasi Data dan Perhitungan Komputasi

Data dibangkitkan dengan generator sintetis (seed tetap) yang menghasilkan order, mesin dan kerusakannya, kongesti pelabuhan, deskripsi produk HS, dan riwayat 4.000 pengiriman carrier. Agen tidak melihat proses pembangkit (logit roll-over tersembunyi); mereka harus mempelajarinya dari data.

3.1 Contoh data

Enam order pertama pada skenario 7 (rilis = hari order masuk; beban kerja = jumlah waktu proses tiga tahap pada kecepatan 1; closing dijanjikan = closing kapal yang dijanjikan sales):

Order	HS	Kontainer	Nilai (USD)	Rilis (hari)	Beban kerja (hari)	Closing dijanjikan	LSD
#0	9405	3	90.279	10,5	5,9	26	31
#1	9401	1	93.349	6,2	5,4	21	26
#2	4414	2	22.068	1,1	2,8	10	15
#3	9401	2	70.880	1,2	5,9	17	22
#4	4414	1	17.935	4,9	6,4	21	26
#5	9403	1	13.214	11,2	6,6	28	33

Tiga carrier (data referensi, ASUMSI):

Carrier	Tarif/kontainer	Transit	Offset closing (hari)	Klaim keandalan	P(roll-over) dasar (logit)
EcoLine	\$1.800	24 hari	0 + 7k	0,95	0,18
MidSea	\$2.100	21 hari	3 + 7k	0,93	0,08
PrimeExpress	\$2.600	18 hari	5 + 7k	0,98	0,03

Parameter simulasi utama:

Parameter	Nilai	Keterangan
Stasiun x mesin	3 x 2	Cutting, Assembly, Finishing; kecepatan mesin N(1; 0,05)
Beban kerja rata-rata per tahap	0,9 / 1,8 / 1,4 hari	dikali faktor kuantitas 0,6-1,5
Laju kerusakan mesin	0.035 per hari	perbaikan 1.5-4.0 hari; indikasi dini 1 hari (deteksi 80%)
Lembur	x1.35	biaya 45 USD per hari operasi; anggaran 12 tahap per skenario
Kesalahan HS manual	8,0%	koreksi bea cukai +3 hari; ambang confidence ML tau = 0.6
Dokumen kurang	6,0%	+1.5 hari; dokumen dasar 1.0 hari
Truk ke pelabuhan	1.5 hari	toleransi LSD +2 hari dari keberangkatan kapal yang dijanjikan
Biaya sentuhan manusia	\$12	persetujuan menambah 0,25 hari; nilai order >= \$50.000 wajib persetujuan
Air freight	5x tarif sea	berangkat H+1, tanpa roll-over
Data volume scout	1,5 MB vs 27 KB	dump jadwal remote vs state agen + hasil (ASUMSI)

Seluruh parameter di atas adalah asumsi pemodelan dari penulis (perusahaan fiktif, data sintetis). Nilai riil harus dikalibrasi dari ERP/MES/TMS perusahaan sebelum keputusan bisnis diambil.

3.2 Perhitungan manual yang dapat diperiksa

Setiap contoh berikut dihitung oleh fungsi yang sama dengan yang dipakai simulator (output kode ada di outputs/worked_example.json), sehingga dapat diverifikasi dengan kalkulator.

1. Dispatch dengan critical ratio (Bab 3-4)

Pada t = 5 hari tiga job menunggu satu stasiun. Job J1: tenggat 12,5, sisa kerja 3,2; J2: 10,5 dan 4,0; J3: 9,0 dan 1,4. $CR = (d - t)/W$: J1 = (12,5-5)/3,2 = 2,34; J2 = (10,5-5)/4,0 = 1,375; J3 = (9,0-5)/1,4 = 2,86. Urutan: J2 > J1 > J3 (CR terkecil paling mendesak).

2. Tawaran Contract Net antar mesin

Job baru ($w = 1,8$ hari) pada $t = 5$. M2a: beban 2,4, kecepatan 1,02: $ETA = 5 + (2,4+1,8)/1,02 = 9,12$. M2b: beban 0,9, kecepatan 0,97: $ETA = 5 + (0,9+1,8)/0,97 = 7,78$. Order Agent memberi ACCEPT ke M2b dan REJECT ke M2a. Bila M2b diberi indikasi rusak sampai $t = 7,5$, ETA-nya menjadi $7,5 + 2,7/0,97 = 10,28$ sehingga M2a menang (condition monitoring).

3. Pemilihan carrier: skor hibrida vs biaya harapan

Order senilai \$38.000, 2 kontainer, tiba di gerbang $t = 15,2$, $LSD = 22$, kongesti 0,55. EcoLine: biaya \$3.600, berangkat hari 24, $p = 0,08$, $z = 89,8$, $g = 0$, $h = 0,0$, $E[biaya] = \$4.098$; MidSea: biaya \$4.200, berangkat hari 20, $p = 0,10$, $z = 87,6$, $g = 1$, $h = 88,5$, $E[biaya] = \$4.303$; PrimeExpress: biaya \$5.200, berangkat hari 22, $p = 0,03$, $z = 77,9$, $g = 1$, $h = 86,4$, $E[biaya] = \$5.244$. Aturan hibrida memilih MidSea (EcoLine gugur karena berangkat setelah LSD, $g = 0$); aturan biaya-harapan murni memilih EcoLine yang lebih murah tetapi berisiko terlambat. Air freight (\$21.000) tidak dipilih karena lebih mahal daripada biaya harapan.

4. Risiko roll-over (regresi logistik, kebenaran tersembunyi)

EcoLine dengan kongesti 0,6, musim puncak, buffer 2 hari: $\text{logit} = -1,55 + 1,8(0,6) + 1,1(1) - 0,3(2) = 0,03$; $p = 1/(1+e^{-0,03}) = 0,507$. Untuk PrimeExpress pada kondisi sama $p = 0,139$. Model ML Risk Agent memperkirakan p ini dari data historis (AUC 0,76).

5. Klasifikasi HS dengan kemiripan kosinus

Query 'teak dining chair'. Dokumen 'teak dining chair oiled (HS 9401)': irisan 3 kata, $\cos = 3/(\sqrt{3} \times \sqrt{4}) = 0,866$. Dokumen 'teak dining table (HS 9403)': irisan 2 kata, $\cos = 2/(\sqrt{3} \times \sqrt{3}) = 0,667$. Pada sistem sebenarnya vektor berupa TF-IDF n-gram kata + karakter; tetangga terdekat memberi suara berbobot kosinus dan confidence $< 0,60$ diserahkan ke manusia.

6. Pembaruan trust carrier

$T = 0,80$ dan kargo terangkut ($q = 1$): $T' = 0,8(0,8) + 0,2(1) = 0,84$. Bila roll-over ($q = 0,2$): $T' = 0,68$ (conditional); roll-over kedua: $T' = 0,584 < 0,60$ sehingga carrier diblokir sementara oleh gerbang kelayakan g .

7. Q-learning untuk keputusan lembur

Contoh dari kuliah: $Q = 2,0$; $\alpha = 0,2$; $r = 5$; $\gamma = 0,9$; $\max Q' = 4$: target = 8,6, TD error = 6,6, Q baru = 3,32. Contoh kita: $Q(s, \text{lembur}) = -120$; $r = -45 \times 1,4/1,35 = -46,7$; $\max Q' = -60$; $\alpha = 0,1$; $\gamma = 0,97$: target = -104,9; TD = 15,1; Q baru = -118,5.

8. Biaya satu order end-to-end (skenario 7, order #10, statis vs multi-agent)

Statis: freight \$5.400, penalti \$1.027, holding \$74, manusia \$72 (sea:EcoLine*, terlambat 5 hari). Multi-agent: freight \$5.400, penalti \$1.027, holding \$91, manusia \$0 (sea:EcoLine*, terlambat 5 hari). Contoh penalti: order \$38.000 terlambat 5 hari = $0,004 \times 38.000 \times 5 + 45 \times 5 = \985 ; 12 hari = \$4.264 (termasuk diskon 5% L/C basi).

9. Metrik sistem multi-agent (Bab 4)

Speedup 1.000 task: 100 s vs 29 s pada 4 agen: $S = 3,45$, efisiensi = 0,86. Redundansi 3 agen $R = 0,9$: $R_{\text{sys}} = 0,999$. Biaya komunikasi satu pesan 8 KB pada 8 Mbps dan 20 ms: 28,2 ms. Jain: beban merata 1,00; beban timpang (4,1,1,1) 0,64. Utilisasi mesin pada simulasi: Jain = 0,89.

10. Negosiasi tarif dan Nash bargaining (modul negosiasi)

Pembeli membuka \$1.900 (batas \$2.300), carrier membuka \$2.600 (batas bawah \$2.000), $T = 4$, $\beta = 1$. Ronde 1: 2.000 vs 2.450; ronde 2: 2.100 vs 2.300; ronde 3: 2.200 vs 2.150 sehingga sepakat di \$2.175 (ronde 3). Untuk 2 kontainer surplus pembeli \$250, carrier \$350, total \$600. Nash product tertinggi (0,222) pada harga \$2.100-\$2.200.

11. Migrasi Scout Agent

Host dengan trust $\geq 0,80$ dan risiko $\leq 0,20$ boleh dimigrasi. EcoLine edge (trust 0,71, risiko 0,30) ditolak walau latensinya terbaik; skor komposit hanya meranking host yang lolos (Bab 4). Data yang dipindahkan per skenario: 18,6 MB (scout) vs 54,0 MB (remote pull); penghematan 65%.

3.3 Simulasi penuh

Simulator diskret (langkah 0,05 hari) menjalankan ketiga arsitektur pada skenario yang sama (common random numbers): keberuntungan yang sama untuk kerusakan mesin, HS, dokumen, dan roll-over, sehingga selisih murni akibat arsitektur/kebijakan. Hasilnya dibahas pada Bagian 7 (300 skenario evaluasi, seed 0-299).

4. Rumus Notasi Matematika dan Arti Simbol

Rumus dikelompokkan A-H. Rumus bertanda Bab 3/4/5 mengikuti materi kuliah; ASUMSI menandai pilihan pemodelan penulis.

A. Agen dan sistem multi-agen

$$A = \langle G, B, I, M, C, R, P, T \rangle, \quad s_{t+1} = F(s_t, o_t, a_t)$$

G goal, B belief, I intention, M memory, C context, R reasoning, P planning, T tools (Bab 3). s_t keadaan sistem, o_t observasi, a_t aksi, F fungsi transisi lingkungan.

$$MAS = \langle \mathcal{A}, E, S, O, Act, C, \Phi \rangle, \quad a_i = \langle G_i, B_i, I_i, M_i, \pi_i \rangle$$

A himpunan agen, E lingkungan, S state, O observasi, Act aksi, C komunikasi, Phi aturan interaksi (protokol); π_i kebijakan keputusan agen i (Bab 4).

$$a^* = \arg \max_a U(a \mid s, g, c) \quad \text{s.t.} \quad \text{policy}(a) = 1$$

Agen rasional memilih aksi dengan utilitas tertinggi U yang tetap memenuhi kebijakan/constraint (budget, compliance, wewenang). s state, g goal, c konteks.

$$\text{autonomy} = \mathbf{1}[\text{risk} < \rho \wedge \text{conf} > \tau \wedge \text{authority} = 1]$$

Aksi dieksekusi otomatis (level 4, delegate) hanya jika risiko < rho, confidence > tau, dan agen berwenang; selain itu perlu persetujuan manusia (level 2).

B. Model masalah ekspor

$$J = C_{\text{frit}} + C_{\text{hold}} + C_{\text{ot}} + C_{\text{human}} + \sum_i \text{Pen}(L_i)$$

Biaya total per skenario yang diminimalkan: freight, penyimpanan barang jadi, lembur, biaya sentuhan manusia, dan penalti keterlambatan tiap order i (Bab 4: service-cost objective).

$$\text{Pen}(d) = 0.004 V d + 45 d + 0.05 V \cdot \mathbf{1}[d > 10]$$

V nilai order (USD), d hari keterlambatan di atas toleransi. 0,4% nilai per hari + 45 USD/hari demurrage/storage + diskon 5% bila L/C basi ($d > 10$). ASUMSI pemodelan.

$$c_j(t) = o_j + 7 \left\lceil \frac{t - o_j}{7} \right\rceil, \quad \text{dep} = c_j + 3 + 7 \cdot \mathbf{1}[\text{rolled}]$$

$c_j(t)$ closing kapal carrier j pertama yang $\geq t$ (kapal berangkat mingguan, offset o_j); keberangkatan = closing + 3 hari, +7 hari bila kargo tidak terangkut (roll-over).

$$L = \max(0, \text{dep} - \text{LSD})$$

L keterlambatan; LSD (latest shipment date) = keberangkatan kapal yang dijanjikan + toleransi 2 hari.

C. Penjadwalan produksi (Contract Net)

$$CR_i = \frac{d_i - t}{W_i}$$

Critical ratio: d_i batas waktu tiba di gerbang pelabuhan, t waktu sekarang, W_i sisa beban kerja. CR terkecil (paling mendesak) dikerjakan lebih dulu.

$$\text{ETA}_m = t_0 + \frac{L_m + w}{v_m}$$

Tawaran (bid) agen mesin m: t_0 waktu mulai (setelah perbaikan bila mesin rusak/terindikasi rusak), L_m beban antrean, w kerja baru, v_m kecepatan mesin.

$$\text{score}_i = 0.5 C_i + 0.3 T_i + 0.2 R_i$$

Skor tawaran CNP (Bab 4): C biaya ternormalisasi, T ketepatan waktu, R keandalan. Pemenang = skor tertinggi.

D. Keputusan carrier (hibrida ML + DSS)

$$z_j = 100 \left(w_c \frac{c_{\min}}{c_j} + w_t \frac{d_{\min}}{d_j} + w_r T_j \right)$$

Skor DSS carrier j: c_j biaya, d_j keberangkatan, T_j trust; $w_c=0,45$, $w_t=0,25$, $w_r=0,30$ (jumlah = 1). Benefit/cost dinormalisasi seperti Bab 3.

$$h_j = g_j [\alpha z_j + (1 - \alpha) \cdot 100 (1 - p_j)]$$

Skor hibrida (Bab 3): g_j gerbang kelayakan (1 bila trust $\geq 0,60$ dan keberangkatan $\leq$ LSD), p_j probabilitas roll-over dari model ML, $\alpha = 0,55$.

$$E[\text{cost}_j] = c_j + (1 - p_j) \text{Pen}_0 + p_j \text{Pen}_7$$

Biaya harapan: Pen_0 penalti bila kargo terangkut, Pen_7 bila tergeser 7 hari (roll-over). Dipakai Risk Agent untuk membandingkan dengan air freight.

$$T_j(t+1) = \lambda T_j(t) + (1 - \lambda) q, \quad \lambda = 0.8$$

Trust eksponensial (Bab 4): $q = 1$ bila kargo terangkut tepat waktu, 0,2 bila roll-over. Trusted $\geq 0,80$; conditional 0,60-0,80; blocked $< 0,60$.

E. Machine learning

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

Kemiripan kosinus vektor TF-IDF deskripsi produk (Compliance Agent, klasifikasi HS) dan vektor teks lain.

$$\text{tfidf}(t, d) = \text{tf}(t, d) \left(\ln \frac{1 + N}{1 + \text{df}(t)} + 1 \right)$$

tf frekuensi term t pada dokumen d, N jumlah dokumen latih, df(t) jumlah dokumen yang memuat t (varian smooth scikit-learn); dipakai untuk n-gram kata dan karakter.

$$\text{conf}(y) = \frac{\sum_{i \in N_k, y_i = y} \cos(x, x_i)}{\sum_{i \in N_k} \cos(x, x_i)}$$

k-NN berbobot kosinus (k=5): confidence = porsi bobot tetangga N_k yang berlabel y. Bila conf $< 0,60$ keputusan diserahkan ke manusia (selective classification).

$$p = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = b + \mathbf{w}^\top \tilde{\mathbf{x}}$$

$$\mathcal{L} = -\frac{1}{n} \sum_i [y_i \ln p_i + (1 - y_i) \ln (1 - p_i)] + \frac{\lambda}{2} \|\mathbf{w}\|^2, \quad \mathbf{w} \leftarrow \mathbf{w} - \eta \nabla \mathcal{L}$$

Regresi logistik Risk Agent: $\tilde{\mathbf{x}}$ fitur terstandarisasi (carrier, kongesti, musim puncak, buffer hari, jumlah kontainer), $y = 1$ bila roll-over, lambda regularisasi L2, eta learning rate.

$$\text{logit } p_j = b_j + 1.8 \text{cong} + 1.1 \text{peak} - 0.3 \text{buf}$$

Proses pembangkit data (kebenaran tersembunyi yang tidak dilihat agen): b_j dasar per carrier, cong indeks kongesti pelabuhan, peak musim puncak, buf selisih hari antara tiba di gerbang dan closing.

$$\text{AUC} = P(s^+ > s^-), \quad \text{Brier} = \frac{1}{n} \sum_i (p_i - y_i)^2$$

AUC peluang skor kasus positif melebihi negatif; Brier skor kalibrasi probabilitas (lebih kecil lebih baik).

$$\hat{\beta} = \frac{\sum_t (t - \bar{t})(x_t - \bar{x})}{\sum_t (t - \bar{t})^2}$$

Kemiringan tren percept sequence sensor mesin (Bab 2: 55, 60, 64, 72, 80 derajat C). Tren naik = sinyal risiko kerusakan sebelum gagal.

F. Reinforcement learning

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

Q-learning (Bab 4-5): s = (bucket slack, bucket nilai order, tahap), a in {normal, lembur}, r = -biaya lembur; reward akhir = -penalti. α learning rate, γ discount.

G. Koordinasi dan negosiasi

$$p_B(t) = p_B^0 + (p_B^{\max} - p_B^0) \left(\frac{t}{T} \right)^\beta$$

Konsesi bergantung waktu (Bab 4): pembeli menaikkan tawaran dari p_B^0 menuju batas $p_B^{\max}$ dalam T ronde; β mengatur kecepatan konsesi. Sepakat bila tawaran pembeli $\geq$ permintaan penjual.

$$x^* = \arg \max_x \prod_i [U_i(x) - d_i]$$

Nash bargaining: memaksimalkan hasil kali keuntungan relatif tiap pihak terhadap utilitas bila gagal sepakat (d_i).

$$S(n) = \frac{T_1}{T_n}, \quad \eta(n) = \frac{S(n)}{n}, \quad R_{\text{sys}} = 1 - \prod_i (1 - R_i)$$

Speedup dan efisiensi paralel; keandalan sistem dengan redundansi (3 agen $R=0,9$ memberi 0,999). Sumber: Bab 4 sub-bab Skalabilitas.

$$C_{\text{comm}} = \sum_m \left(\frac{L_m}{B} + \tau \right), \quad \text{Jain}(x) = \frac{(\sum x_i)^2}{n \sum x_i^2}$$

Biaya komunikasi: L ukuran pesan, B bandwidth 8 Mbps, τ latensi 20 ms. Indeks keadilan Jain untuk pemerataan utilisasi mesin (1 = merata).

H. Keamanan, trust, dan mobilitas agen

$$\sigma = \text{HMAC}_K(H(m)), \quad \text{accept} \Leftrightarrow \text{nonce} \notin \text{Seen} \wedge |t_{\text{now}} - t_m| < \Delta \wedge a \in \text{Cap}_i$$

Integritas pesan (tanda tangan HMAC-SHA256), pertahanan replay (nonce + jendela waktu Δ), dan capability check (aksi harus ada pada himpunan wewenang agen).

$$\text{migrate} \Leftrightarrow T_{\text{host}} \geq \theta_T \wedge \text{Verify}(\sigma) \wedge \text{Risk} \leq \theta_R$$

$$\text{Score} = 0.5 (1 - \text{lat}_{\text{norm}}) + 0.5 T_{\text{host}}$$

Syarat migrasi Scout Agent (Bab 4-5): $\text{trust host} \geq 0,80$, state terverifikasi, risiko $\leq 0,20$. Skor komposit hanya meranking host yang lolos; keamanan adalah constraint keras.

5. Tiga Penelitian Serupa (Topik Order-to-Shipment Ekspor)

Hathikal, S., Chung, S. H., & Karczewski, M. (2020). Prediction of ocean import shipment lead time using machine learning methods. *SN Applied Sciences*, 2, 1272.

Ringkasan: Memprediksi lead time pengiriman laut dengan regresi logistik multinomial, pohon keputusan, SVM, Naive Bayes, dan k-NN untuk kepentingan shipper, carrier, forwarder, dan consignee.

Relevansi: Mendukung pemakaian model klasik/explainable untuk risiko pengiriman; EOS-MAS memakai regresi logistik untuk peluang roll-over.

Tautan: <https://link.springer.com/article/10.1007/s42452-020-2951-5>

Lee, E., Kim, S., Kim, S., Jung, S., Kim, H., & Cha, M. (2024). Explainable Product Classification for Customs. *ACM Transactions on Intelligent Systems and Technology*, 15(2), Art. 25. doi:10.1145/3635158.

Ringkasan: Model XAI untuk membantu petugas bea cukai menetapkan 6 digit kode HS dari deskripsi barang, disertai alasan yang dapat dibaca.

Relevansi: Dasar Compliance Agent: klasifikasi teks HS dengan confidence dan eskalasi ke manusia (selective classification).

Tautan: <https://dl.acm.org/doi/10.1145/3635158>

Ouelhadj, D., & Petrovic, S. (2009). A survey of dynamic scheduling in manufacturing systems. Journal of Scheduling, 12, 417-431. doi:10.1007/s10951-008-0090-8.

Ringkasan: Tinjauan penjadwalan dinamis (heuristik, meta-heuristik, sistem multi-agen, teknik AI lain) saat terjadi gangguan seperti kerusakan mesin dan order mendadak.

Relevansi: Dasar penjadwalan reaktif EOS-MAS: re-kontrak job saat mesin rusak, critical ratio, dan perbandingan dengan jadwal statis.

Tautan: <https://link.springer.com/article/10.1007/s10951-008-0090-8>

6. Intelligent Agent System


6.1 Mengapa multi-agent, bukan single agent?

Kriteria pemilihan arsitektur mengikuti Bab 4 (latensi dan bandwidth, fault tolerance, optimalitas global, biaya koordinasi):


Kriteria (Bab 4)	Terpusat	Terdesentralisasi	Hybrid	Posisi EOS-MAS
Latensi dan bandwidth	Sedang	Rendah	Rendah-sedang	Hybrid: CNP lokal per operasi
Fault tolerance	Rendah (single point of failure)	Tinggi	Tinggi	Kegagalan satu agen tidak menghentikan sistem
Optimalitas global	Tinggi	Lokal	Cukup tinggi	Aturan keputusan bersama + governance
Biaya koordinasi	Fan-in O(n) pada koordinator	Tinggi (banyak pesan)	Sedang	CFP dibatasi (fan-out 3)

Alasan	Penjelasan dan bukti
Batas organisasi	Carrier, bea cukai, dan pelabuhan adalah pihak otonom yang tidak dapat dikendalikan planner pusat; mereka hanya dapat dinegosiasikan (CFP/PROPOSE) dan mengungkap sebatas tawaran.
Lingkungan partially observable, stochastic, dynamic	Sesuai Tabel 2.1 (Bab 2), lingkungan seperti ini menuntut memori, penalaran probabilistik, perencanaan, koordinasi, dan pembelajaran; tugas heterogen lebih mudah diuji jika dipecah per agen.
Ketahanan terhadap single point of failure	Pada gangguan bidang kontrol di 50% skenario, tepat waktu turun dari 87,8% ke 85,5% (agen tunggal) vs 87,8% ke 87,3% (multi-agen).
Beban node puncak	Pada 240 order dan 120 mesin, koordinator menerima 879 pesan/hari pada hari tersibuk vs 114 pada agen tersibuk multi-agen (7,7x lebih ringan); total pesan 21% lebih sedikit (asumsi heartbeat koordinator tiap 6 jam).
Modularitas	Agan dapat diganti/diuji terpisah (ablation): mis. mengganti model risiko atau kebijakan lembur tanpa menyentuh agen lain; carrier baru cukup ditambah sebagai agen.

Catatan penting: pada simulasi dasar, agen tunggal (inti kognitif terpusat) dan multi-agen menghasilkan kualitas keputusan identik (selisih biaya berpasangan = 0 [0; 0] USD) karena keduanya memakai aturan keputusan yang sama. Untuk satu pabrik, satu pemilik, dan puluhan order, agen tunggal sudah memadai. Rekomendasi: arsitektur hybrid: satu inti kognitif per pabrik (Order + Production) dan negosiasi multi-agen pada batas organisasi (carrier, bea cukai), dengan governance sebagai bidang kontrol.



Gambar 2. Ketahanan: kinerja saat bidang kontrol gagal selama 2-5 hari (statis tidak terpengaruh karena tidak memakai koordinator).



Gambar 3. Skala: beban pesan puncak pada satu node, total pesan, dan tingkat layanan ketika order dan mesin bertambah (fan-out CFP dibatasi 3).

6.2 Tiga penelitian yang memakai agen cerdas

Smith, R. G. (1980). The Contract Net Protocol: High-level communication and control in a distributed problem solver. IEEE Transactions on Computers, C-29(12), 1104-1113.

Ringkasan: Memperkenalkan alokasi tugas terdesentralisasi: manajer mengumumkan tugas (CFP), kontraktor menawarkan, pemenang dipilih; dapat re-kontrak bila gagal.

Relevansi: Protokol inti EOS-MAS untuk dispatch mesin dan pemilihan carrier (Bab 4 bagian Contract Net).

Leitao, P. (2009). Agent-based distributed manufacturing control: A state-of-the-art survey. Engineering Applications of Artificial Intelligence, 22(7), 979-991.

Ringkasan: Survei kontrol manufaktur terdistribusi berbasis agen: fleksibilitas, kemampuan bereaksi terhadap gangguan, dan tantangan integrasi.

Relevansi: Menjustifikasi agen mesin/order sebagai unit otonom dan pendekatan hibrida (koordinasi terdesentralisasi + kontrol ringan).

Tautan: <https://doi.org/10.1016/j.engappai.2009.05.005>

Zhao, Z., Tang, D., Liu, C., Wang, L., Zhang, Z., Zhu, H., Chen, K., Nie, Q., & Ji, Y. (2024). A Large Language Model-based multi-agent manufacturing system for intelligent shopfloor. arXiv:2405.16887.


Ringkasan: Sistem multi-agen berbasis LLM untuk shopfloor pintar dengan modul agen dan cara kolaborasi, meminimalkan intervensi manusia.

Relevansi: Arah lanjutan EOS-MAS: LLM sebagai lapisan bahasa (ekstraksi dokumen, penjelasan), tetap dibatasi kebijakan dan aturan deterministik.


Tautan: <https://arxiv.org/abs/2405.16887>

Verifikasi: metadata Hathikal dkk., Lee dkk., Ouelhadj & Petrovic, Leitao, dan Zhao dkk. dicek melalui pencarian web pada sesi pengerjaan (situs penerbit tidak dapat dibuka langsung dari lingkungan kerja). Smith (1980) dan halaman jurnal Leitao ditulis dari pengetahuan penulis: mohon diverifikasi sebelum pengumpulan.

6.3 Diagram rencana sistem




Gambar 4. Arsitektur EOS-MAS: manusia, governance (bidang kontrol), bus pesan, agen internal, dan sistem/organisasi eksternal.



Gambar 5. Contract Net Protocol untuk dispatch satu operasi; tiap leg divalidasi FSM dan ditandatangani HMAC.

Cognitive cycle of one agent: $A = \langle G, B, I, M, C, R, P, T \rangle$



Gambar 6. Siklus kognitif tiap agen (Bab 3): perceive, belief, desire, intention, plan/tools, act/learn, dengan umpan balik $s(t+1)=F(s,o,a)$.

Alur proses.

(1) Order masuk: Order Agent dibuat dan Compliance Agent langsung menyiapkan dokumen/HS paralel dengan produksi. (2) Untuk tiap tahap, Order Agent mengirim CFP ke Machine Agent stasiun terkait; mesin menawarkan ETA; ACCEPT ke ETA terbaik. (3) Learning Agent memutuskan lembur bila slack menipis; Governance membatasi anggaran. (4) Bila mesin rusak/terindikasi, pekerjaannya di-CFP ulang (re-kontrak). (5) Setelah produksi dan dokumen siap, Scout Agent memeriksa jadwal carrier, lalu CNP carrier dengan skor hibrida (Risk Agent memberi p, trust memberi T) dan level otonomi ditetapkan. (6) Hasil (terangkut/roll-over) mengembalikan trust dan reward ke agen.

6.4 Agen dan komponen internal

Setiap agen dimodelkan sebagai $A = \langle G, B, I, M, C, R, P, T \rangle$ (Bab 3). Tabel berikut merinci fungsi tiap agen dan alasan setiap komponen:

Agen	Tipe	Belief / Desire / Intention	Komponen internal dan tools	Input -> Output	Metode	Otonomi
Order Agent (x n)	Hybrid, statis, deliberatif	B: ETA, antrean, trust, kongesti. D: kirim $\leq$ LSD dengan biaya minimum. I: memilih bid mesin dan carrier	Estimator slack, kalkulator penalti, klien CNP, kebijakan expedite	Order + bid -> ACCEPT/REJECT, booking	Aturan + DSS hibrida	Delegate (nilai < \$50k)
Machine Agent (x6)	Reaktif + deliberatif, statis	B: antrean, kesehatan mesin. D: memaksimalkan throughput. I: menawarkan ETA, memproses job	Estimator ETA, monitor kondisi (tren sensor), antrean critical ratio	CFP -> PROPOSE(ETA); INFORM(done)	Regresi slope + aturan	Delegate
Compliance Agent	Deliberatif, statis	B: deskripsi produk, aturan dokumen. D: dokumen benar dan siap sebelum produksi selesai. I: menetapkan HS, meminta review	TF-IDF kata+karakter, k-NN kosinus, mesin aturan lisensi, penilai confidence	Deskripsi -> HS + confidence; review manusia bila < 0,60	ML klasik (NLP) + aturan	Delegate / Approve
Risk Agent	Deliberatif, statis	B: fitur pelabuhan/carrier, riwayat outcome. D: estimasi risiko akurat. I: memberi p roll-over dan trust	Regresi logistik (numpy), registri trust, kalibrasi (Brier)	Fitur -> p; outcome -> trust update	Supervised ML + trust	Supervise
Learning Agent	Learning agent (Bab 2)	B: state (slack, nilai, tahap). D: meminimalkan biaya+penalti. I: normal atau lembur	Performance element, critic (reward), learning element (Q), problem generator (epsilon-greedy), guardrail anggaran	State -> aksi; outcome -> update Q	Q-learning tabular (RL)	Supervise, batas anggaran
Governance & Security Agent	Deliberatif, statis (bidang kontrol)	B: kebijakan, identitas, trust, level otonomi. D: keputusan sah dan dapat diaudit. I: izinkan/tolak/eskalasi	Policy engine, capability set, HMAC + nonce, FSM protokol, audit log rantai-hash	Pesan/aksi -> allow/deny/level 1-4	Rule-based (deterministik)	Delegate
Carrier Agent (x3, eksternal)	Reaktif, eksternal	B: kapasitas dan jadwal kapal. D: mengisi kapal. I: menawarkan tarif dan closing	Tabel tarif, jadwal mingguan	CFP -> PROPOSE(rate, closing)	Aturan	Di luar kendali

Agen	Tipe	Belief / Desire / Intention	Komponen internal dan tools	Input -> Output	Metode	Otonomi
Scout Agent	Mobile, deliberatif	B: host dan trust. D: mendapat jadwal terkini dengan trafik minimal. I: migrasi jika aman	Serialisasi state, verifikasi hash/HMAC, pilih host, sandbox	Host tepercaya -> closing time (2 KB)	Aturan + skor komposit	Supervise

6.5 Komunikasi, keamanan, dan trust

Pesan berupa tuple $m = \langle s, r, p, c, o, l, id, t \rangle$ dengan performative REQUEST/INFORM/PROPOSE/ACCEPT/REJECT/CFP/CONFIRM (Bab 4). Setiap percakapan Contract Net divalidasi FSM (IDLE, BIDDING, AWARDED, COMPLETED), ditandatangani HMAC-SHA256, memiliki nonce dan jendela waktu, dan dicatat pada audit log berantai-hash sehingga perubahan dapat dideteksi. Tujuh uji serangan dijalankan pada bus pesan:

Serangan / pelanggaran	Hasil pada bus pesan
spoofed sender	blocked: unknown sender (spoofing)
tampered payload	blocked: bad signature (tampering/spoofing)
replayed message	blocked: replay detected
capability abuse (machine issues ACCEPT)	blocked: capability denied: M1a may not ACCEPT
protocol violation (ACCEPT without CFP)	blocked: protocol violation in CNP-x/5: ACCEPT while IDLE
stale message (timestamp outside window)	blocked: replay detected
tampered mobile-agent state	blocked: state hash mismatch -> migration refused, remote pull

Trust carrier diperbarui $T(t+1) = 0,8 T(t) + 0,2 q$ dan menjadi bagian gerbang kelayakan g ; carrier dengan $T < 0,60$ diblokir sementara.

6.6 Metode AI / ML / DL / RL dan alasan pemilihan

Kriteria pemilihan model (Bab 3): akurasi dan explainability, latensi dan biaya, privasi dan data, skalabilitas. Prinsip Bab 1: pilih model paling sederhana yang memenuhi kebutuhan akurasi, latensi, biaya, explainability, dan governance.

Komponen	Metode	Kelas	Alasan pemilihan	Mengapa bukan DL/LLM (sekarang)
Klasifikasi HS	TF-IDF + k-NN kosinus	ML klasik (NLP)	Deskripsi pendek, ~840 contoh; akurasi 91,9% dan confidence dapat dijelaskan; latensi ms	Data kecil; DL/LLM lebih baik hanya bila kosakata besar; LLM ditambahkan kelak untuk ekstraksi dokumen
Risiko roll-over	Regresi logistik	ML supervised	Data tabular 4.000 pengiriman; AUC 0,76; bobot dapat dibaca tim logistik; probabilitas terkalibrasi	Pada data tabular kecil, model linier/tree setara DL (Bab 1); XGBoost sebagai pembanding tahap berikut
Kesehatan mesin	Slope percept sequence	Statistik	Bab 2: tren lebih informatif daripada nilai tunggal	Sensor sedikit; DL (LSTM) relevan bila data getaran tersedia
Keputusan lembur	Q-learning tabular	RL	Ruang state kecil (66 state), keputusan sekuensial dengan reward tertunda	Deep RL tidak diperlukan; risiko tidak stabil dan sulit diaudit
Pemilihan carrier	DSS berbobot + ML + gerbang kebijakan	Hibrida (Bab 3)	Skor hibrida h ; kelayakan sebagai constraint keras	Keputusan berdampak finansial harus dapat dijelaskan
Dispatch mesin	Critical ratio + Contract Net	AI klasik / aturan	Deterministik, cepat, teruji di literatur penjadwalan	Tidak perlu belajar untuk aturan yang sudah baik
Keamanan dan otonomi	HMAC, nonce, FSM, capability	Deterministik	Jaminan keamanan harus pasti, bukan probabilistik	-
Rencana lanjutan	LLM+RAG, LSTM/TFT, GNN	DL / LLM	Ekstraksi L/C dan invoice, prediksi ETA, graf jaringan pelabuhan (Bab 5)	Belum diimplementasikan di Tugas 1

Kesimpulan: EOS-MAS adalah sistem hibrida AI klasik + ML supervised + RL kecil + aturan deterministik, bukan Deep Learning. Alasannya: data tabular/teks kecil, kebutuhan explainability untuk keputusan berdampak finansial, latensi dan biaya rendah, serta kebutuhan jaminan keamanan yang pasti.

6.7 Tingkat otonomi dan governance

Level (Bab 2)	Keputusan pada EOS-MAS	Rata-rata per skenario	Kendali
4 Delegate	Dispatch operasi, HS confidence $\geq 0,60$, carrier order $< \$50k$	55,2 (87,2%)	Otomatis, audit trail
3 Supervise	Lembur dalam anggaran	1,4	Agen bertindak, manusia dapat override


Level (Bab 2)	Keputusan pada EOS-MAS	Rata-rata per skenario	Kendali
2 Approve	HS confidence rendah, order $\geq$ \$50k, air freight, lembur di luar anggaran	6,7	Human-in-the-loop
1 Assist	Belum dipakai pada simulasi (mode rekomendasi saja)	0,0	Rekomendasi

Aturan otonomi (Bab 3): aksi otomatis hanya jika risiko $< \rho$, confidence $> \tau$, dan agen berwenang. Human-in-the-loop diterapkan pada risiko tinggi/confidence rendah. Observability: jumlah pesan, id percakapan, audit log, dan anggaran lembur menjadi batas berhenti/eskalasi (Bab 3: stop if steps $> K$ atau cost $> B$ atau conf $< \tau$).

6.8 Mobile agent (Scout)

Scout Agent berpindah ke host carrier/pelabuhan untuk membaca jadwal secara lokal lalu kembali membawa ~2 KB, alih-alih menarik dump jadwal 1,5 MB (Bab 5). Migrasi mensyaratkan trust host $\geq 0,80$, risiko $\leq 0,20$, dan state terverifikasi (SHA-256 + HMAC); jika tidak, sistem jatuh ke remote pull.

Host	Trust	Latensi (ms)	Risiko	Skor	Keputusan
carrier_EcoLine_edge	0,71	12	0,30	0,85	reject (remote pull)
carrier_MidSea_edge	0,90	18	0,10	0,72	migrate
carrier_Prime_edge	0,86	25	0,15	0,43	migrate
port_community_node	0,93	15	0,08	0,85	migrate



Gambar 7. Data yang dipindahkan per skenario: scout vs remote pull (host EcoLine tidak lolos trust sehingga tetap remote pull).


7. Implementasi dan Eksperimen

7.1 Rancangan eksperimen

Tiga arsitektur dijalankan pada skenario yang sama: (a) Statis: FIFO, mesin pra-tetap, dokumen setelah produksi, kode HS manual, selalu carrier yang dijanjikan; (b) Agen tunggal: satu inti kognitif terpusat dengan pandangan global, dispatch dinamis, ML-HS, dokumen paralel, dan aturan keputusan hibrida yang sama; (c) Multi-agen EOS-MAS: keputusan yang sama tetapi dinegosiasikan lewat Contract Net antar agen. Karena aturan keputusan (b) dan (c) sama, selisih keduanya mencerminkan struktur interaksi, bukan kepintaran aturan.

Evaluasi: 300 skenario (seed 0-299) x 12 order; interval kepercayaan 95% dari bootstrap 2.000 resample; seed kalibrasi (1000+) dan pelatihan RL (10.000+) terpisah dari seed evaluasi. Kode diuji dengan 20 unit test (pytest).

7.2 Hasil utama




Gambar 8. Hasil utama pada 300 skenario berpasangan (bar galat = CI 95%).

Metrik	Statis (manual/FIFO)	Agen tunggal (inti terpusat)	Multi-agen (EOS-MAS)
Tepat waktu	63,9% [62,1%; 65,6%]	87,6% [86,5%; 88,8%]	87,6% [86,5%; 88,8%]
Rata-rata hari terlambat	2,11 [1,98; 2,24]	0,63 [0,56; 0,70]	0,63 [0,56; 0,70]
Biaya total per skenario (USD)	60.980 [60.075; 61.873]	50.123 [49.418; 50.842]	50.123 [49.418; 50.842]
Freight	53.094	47.646	47.646
Penalti keterlambatan	6.475	1.749	1.749
Lembur	0	51	51
Penyimpanan	547	596	596
Sentuhan manusia	864	80	80
Sentuhan manusia per order	6,00	0,56	0,56
Kesalahan HS	8,0%	2,2%	2,2%
Total pesan per skenario	0	723	445
Pesan koordinator pada hari tersibuk	0	51	0
Pesan agen tersibuk (non-koordinator)	0	8	16
Indeks Jain utilisasi mesin	0,92	0,89	0,89

Selisih berpasangan vs statis	Agen tunggal	Multi-agen
Tepat waktu (poin persentase)	+23,8 [+22,1; +25,5]	+23,8 [+22,1; +25,5]
Hari terlambat	-1,48 [-1,59; -1,37]	-1,48 [-1,59; -1,37]
Biaya total per skenario (USD)	-10.857 [-11.403; -10.310]	-10.857 [-11.403; -10.310]
Biaya sentuhan manusia (USD)	-784 [-787; -781]	-784 [-787; -781]

7.3 Ablation: kontribusi tiap komponen

Ablation: what each component contributes



Gambar 9. Ablation MAS: selisih biaya dan tepat waktu terhadap varian lengkap.

Varian MAS	Tepat waktu	Biaya/skenario	Delta biaya	Penalti	Freight	Lembur
MAS (full)	87,8%	49.717	-	1.685	47.308	54
- ML risk model (advertised reliability)	85,4%	47.243	-2.474	1.767	44.796	54
- condition monitoring	88,2%	49.638	-79	1.620	47.296	49
- expedite policy (never overtime)	87,6%	49.717	-0	1.715	47.334	0
expedite = tuned rule (slack<0)	87,9%	49.650	-67	1.615	47.312	54
expedite = always overtime	90,9%	49.357	-360	1.214	46.910	548
expedite = Q trained in abstract env (no transfer)	87,8%	49.721	+4	1.677	47.342	33
- parallel documents	83,1%	51.142	+1.425	2.695	47.746	53
- ML HS classifier (manual HS)	87,8%	49.979	+262	1.691	47.306	54
carrier rule = expected cost	77,1%	46.511	-3.206	2.059	43.744	54
carrier rule = weighted sum only	75,4%	47.036	-2.681	2.371	43.959	54
carrier rule = keep committed carrier (no re-optimisation)	88,2%	55.080	+5.363	1.623	52.788	54
- mobile scout (remote pull)	87,8%	49.717	+0	1.685	47.308	54

Interpretasi.

Sumber penghematan terbesar adalah re-optimasi carrier: mempertahankan carrier yang dijanjikan menaikkan biaya +5.363 USD per skenario dengan tepat waktu hampir sama. Dokumen paralel dengan produksi menyumbang 4,7% poin tepat waktu dan 1.425 USD.

Trade-off biaya vs layanan: menghapus model risiko atau memakai aturan biaya-harapan menurunkan biaya (-2.474 dan -3.206 USD) tetapi menurunkan tepat waktu menjadi 85,4% dan 77,1%. Karena penalti diasumsikan kecil dibanding selisih tarif, aturan biaya murni memilih carrier murah yang berisiko; aturan hibrida (Bab 3) memprioritaskan tingkat layanan. Pilihan bobot adalah keputusan bisnis, bukan kebenaran teknis; kerugian reputasi/L-C tidak dimodelkan sehingga biaya layanan rendah di sini bersifat konservatif.

Klasifier HS ML menurunkan kesalahan dari 8,0% menjadi 2,2% dan biaya manusia; dampak dolar kecil (+262 USD) tetapi mengurangi risiko kepatuhan yang tidak dimodelkan penuh. Scout mobile memangkas data yang dipindahkan 65% (host tidak tepercaya tetap memakai remote pull).

Pembelajaran RL: policy Q yang dilatih di MDP abstrak tidak transfer (+4 USD, hampir tidak pernah lembur), sedangkan Q yang dilatih langsung di simulator setara aturan slack<0 (-67 USD). Menariknya 'selalu lembur (dalam anggaran)' lebih baik (-360 USD, tepat waktu 90,9%): lembur murah dibanding penalti, dan anggaran governance 12 tahap menjadi parameter yang mengikat. Penyebab Q tidak menemukannya adalah reward akhir yang bising dan kredit yang tercampur antar order (credit assignment); perbaikan yang direncanakan: difference reward (Bab 4) dan lebih banyak episode.

7.4 Ketahanan dan skala

Gangguan bidang kontrol: koordinator pusat mati 2-5 hari (agen tunggal) vs satu agen mesin mati pada durasi sama (multi-agen); format sel: tepat waktu / biaya per skenario.

P(gangguan bidang kontrol)	Statis	Agen tunggal	Multi-agen
0,0	64,2% / \$60.463	87,8% / \$49.717	87,8% / \$49.717
0,1	64,2% / \$60.463	87,4% / \$49.786	88,0% / \$49.682
0,2	64,2% / \$60.463	87,2% / \$49.852	87,9% / \$49.663
0,3	64,2% / \$60.463	86,3% / \$50.095	87,8% / \$49.711
0,5	64,2% / \$60.463	85,5% / \$50.240	87,3% / \$49.834


Skala: order dan mesin bertambah proporsional (utilisasi tetap); fan-out CFP dibatasi 3.

Order / mesin	Koordinator: puncak pesan/hari	MAS: agen tersibuk	Total pesan (pusat / MAS)	Tepat waktu (pusat / MAS)
12 / 6	58	15	700 / 452	94,4% / 94,4%
48 / 24	191	33	2.624 / 2.244	99,3% / 97,9%
120 / 60	479	68	6.883 / 5.554	94,4% / 93,3%
240 / 120	879	114	13.973 / 11.034	90,8% / 89,2%


Catatan: agen tersibuk pada MAS umumnya carrier agent (menerima CFP dari semua order); ini memperlihatkan bahwa MAS tidak menghilangkan hotspot, melainkan memindahkannya ke titik yang secara organisasi memang eksternal.

7.5 Model ML dan RL


Model	Metrik	Nilai
Klasifikasi HS (uji 25%)	Akurasi (semua)	91,9%
Klasifikasi HS	Akurasi pada yang otomatis (tau=0,60)	97,5%
Klasifikasi HS	Cakupan otomatis (tau=0,60)	76,2%
Risiko roll-over (uji 25%)	AUC	0,758
Risiko roll-over	Brier (model / baseline base-rate)	0,1021 / 0,1162
Q-learning (MDP abstrak)	Return per order: Q / aturan slack<0 / never	-345 / -339 / -383



Gambar 10. Klasifikasi HS: kurva cakupan-akurasi (selective classification) dan confusion matrix.



Gambar 11. Kalibrasi model risiko roll-over (uji 25%).



Gambar 12. Q-learning: kurva belajar di MDP abstrak, perbandingan policy di MDP, dan perbandingan policy yang sama di simulator penuh.

7.6 Ancaman validitas dan keterbatasan

- Data sintetis dan perusahaan fiktif: tidak ada klaim performa dunia nyata. Kalibrasi ke data ERP/MES/TMS riil adalah langkah wajib berikutnya.
- Aturan keputusan agen tunggal dan multi-agen sengaja disamakan agar perbedaan arsitektur terisolasi; perbandingan dengan optimizer global eksak (MILP) belum dilakukan.
- Keunggulan pesan multi-agen bergantung pada asumsi heartbeat koordinator tiap 6 jam; pada arsitektur pusat yang event-driven selisihnya mengecil.
- Penalti keterlambatan diasumsikan; kerugian reputasi, pembatalan L/C, dan variasi kurs tidak dimodelkan. Ukuran data untuk scout adalah asumsi.
- Model risiko (AUC 0,76) dilatih pada data yang dibangkitkan dari proses logit yang kita tulis; performa nyata akan berbeda. Belum ada uji drift/retraining online.
- Simulasi diskret dengan langkah 0,05 hari; 300 skenario evaluasi (seed 0-299) terpisah dari seed kalibrasi (1000+) dan pelatihan RL (10000+).
- Belum ada LLM/DL, UI dashboard, maupun integrasi API nyata (bea cukai, carrier); ini rencana Project #1.

8. Kesimpulan dan Rencana Berikutnya

EOS-MAS menunjukkan bahwa masalah order-to-shipment ekspor dapat dimodelkan sebagai sistem agen cerdas yang hibrida, aman, dan dapat diaudit. Pada simulasi sintetis, automasi mengangkat tepat waktu dari 63,9% menjadi 87,6% dan menurunkan biaya per order 18%. Multi-agen tidak lebih pintar dari agen tunggal pada skala kecil, tetapi lebih tahan gangguan, lebih ringan pada node puncak, dan sesuai dengan batas organisasi eksportir-carrier-bea cukai; rekomendasi akhir adalah arsitektur hybrid.

Rencana:

- Ganti data sintetis dengan data riil/publik (data perdagangan, jadwal kapal terbuka) dan kalibrasi seluruh parameter; jika perlu adaptasi ke komoditas ekspor lain (mis. briket arang, wood pellet: HS 4402/4401).
- Project #1 (tema domain enterprise): perluas ke Scout/Broker/Worker/Security (Bab 5), dashboard UI/UX (status agen, migrasi, KPI), GNN untuk jaringan pelabuhan-carrier, dan bandingkan dengan sistem statis.
- Perkuat RL: difference reward, replay terkontrol, dan safe-RL dengan constraint eksplisit; bandingkan XGBoost untuk risiko roll-over.
- Tambahkan LLM+RAG untuk ekstraksi dokumen L/C dan invoice dengan human-approval gate; uji drift dan retraining online.
- Bandingkan dengan optimizer global (MILP/OR-Tools) sebagai batas atas optimalitas.

Peta materi kuliah ke implementasi

Materi kuliah	Penerapan pada EOS-MAS	Berkas kode
Bab 1: hibrida prediksi + aturan deterministik; model paling sederhana yang memadai	Risk/Compliance = ML klasik; governance = aturan; DL/LLM ditunda	ml.py, agents di sim.py
Bab 2: PEAS, klasifikasi lingkungan, rational agent, utility + constraint	Bagian 2.3-2.4; $a^* = \operatorname{argmax} U \text{ s.t. policy}$	config.py, sim.py
Bab 2: percept sequence (55->80 C), reactive vs deliberative, level otonomi, learning agent	Condition monitor mesin; hybrid; level 1-4; Learning Agent (critic, learning element, problem generator)	ml.py (slope), rl.py, rl_sim.py
Bab 3: BDI, $A = \langle G, B, I, M, C, R, P, T \rangle$, $s(t+1)=F(s,o,a)$	Tabel agen (6.4), siklus kognitif (6.3)	sim.py
Bab 3: skor hibrida $h = g[\alpha z + (1-\alpha) 100 (1-p)]$, DSS + ML + policy engine	Pemilihan carrier	sim.py (book)
Bab 3: runtime, observability, audit trail, batas berhenti	Log audit rantai-hash, jumlah pesan, anggaran lembur, eskalasi confidence	messaging.py
Bab 4: MAS tuple, ACL, FSM, ontologi, komunikasi	Message $m = \langle s,r,p,c,o,l,id,t \rangle$, FSM Contract Net, ontologi export-mfg-v1	messaging.py
Bab 4: Contract Net, negosiasi konsesi, Nash bargaining, lelang, assignment	Dispatch mesin (CNP), carrier (CNP), tarif (negosiasi)	negotiation.py, sim.py
Bab 4: trust eksponensial, HMAC, replay, capability, migrasi aman	Trust carrier, 7 uji serangan, gerbang migrasi	messaging.py, mobile.py
Bab 4: speedup, R_sys, Jain, C_comm, KPI vector, smart manufacturing	Bagian 3 (contoh 9) dan 7 (metrik sistem)	negotiation.py, experiments.py
Bab 5: mobile agent, serialisasi, migrasi, sandbox, RL mobility, layout Project #1	Scout Agent; Q-learning; struktur laporan mengikuti layout Project #1	mobile.py, rl.py

Referensi

- Hathikal, S., Chung, S. H., & Karczewski, M. (2020). Prediction of ocean import shipment lead time using machine learning methods. SN Applied Sciences, 2, 1272. <https://link.springer.com/article/10.1007/s42452-020-2951-5>

- Lee, E., Kim, S., Kim, S., Jung, S., Kim, H., & Cha, M. (2024). Explainable Product Classification for Customs. ACM Transactions on Intelligent Systems and Technology, 15(2), Art. 25. doi:10.1145/3635158. <https://dl.acm.org/doi/10.1145/3635158>

- Ouelhadj, D., & Petrovic, S. (2009). A survey of dynamic scheduling in manufacturing systems. Journal of Scheduling, 12, 417-431. doi:10.1007/s10951-008-0090-8. <https://link.springer.com/article/10.1007/s10951-008-0090-8>

- Smith, R. G. (1980). The Contract Net Protocol: High-level communication and control in a distributed problem solver. IEEE Transactions on Computers, C-29(12), 1104-1113.

- Leitao, P. (2009). Agent-based distributed manufacturing control: A state-of-the-art survey. Engineering Applications of Artificial Intelligence, 22(7), 979-991. <https://doi.org/10.1016/j.engappai.2009.05.005>

- Zhao, Z., Tang, D., Liu, C., Wang, L., Zhang, Z., Zhu, H., Chen, K., Nie, Q., & Ji, Y. (2024). A Large Language Model-based multi-agent manufacturing system for intelligent shopfloor. arXiv:2405.16887. <https://arxiv.org/abs/2405.16887>

- Prof. Dr. Azhari MT. Materi kuliah AI Agentic Technology Systems for Digital Enterprise Ecosystem, Bab 1-5, Universitas Gadjah Mada.

Repository dan cara menjalankan

GitHub: <https://github.com/AdityaIKO/Agentic-Enterprise> (branch claude/compassionate-noether-fhv9vc).

```

pip install -r requirements.txt | cd src && python -m eosmas.experiments | python -m eosmas.figures | python -m eosmas.worked_example | cd .. && python docs/build_pdf.py && python docs/build_pptx.py | pytest tests

```

Isi NAMA dan NIM pada docs/content.py sebelum membangun ulang dokumen.