


# MALQS: Multi-Agent Lead Qualification & Scoring System

## Laporan Progres Tugas 1

Agentic Enterprise - Magister AI | Tugas 1 - Laporan Progres

Penyusun: [Isi nama Anda] ([Isi NIM]) - pengerjaan individu

Repositori kode: <https://github.com/AdityaIKO/Agentic-Enterprise>



# 1. Peran Anggota Tim

| Peran                         | Tanggung jawab                                                                    |
|-------------------------------|-----------------------------------------------------------------------------------|
| Product owner & analis bisnis | Merumuskan masalah, memilih topik, menentukan KPI (AUC, lift, konversi per tier). |
| Data engineer                 | Membuat generator data sintetis, pembersihan data (dedup, imputasi).              |
| ML engineer                   | Merancang fitur, implementasi Logistic Regression (numpy), evaluasi & baseline.   |
| Agent architect               | Merancang 5 agen + orchestrator, blackboard, feedback loop, diagram sistem.       |
| Dokumentasi & presentasi      | Menyusun laporan PDF, PPT, dan repositori GitHub.                                 |

Catatan: pekerjaan ini dikerjakan individu (mahasiswa bergabung terlambat), sehingga seluruh peran di atas dipegang satu orang. Claude Code digunakan sebagai asisten penulisan kode dan dokumen; seluruh keputusan desain, hasil, dan klaim ditinjau oleh penulis.

# 2. Deskripsi Problem

Tim sales B2B menerima ratusan hingga ribuan lead per bulan dari web form, webinar, e-mail, dan daftar dingin (cold list). Kapasitas sales terbatas, sehingga lead yang paling siap membeli sering terlambat ditindaklanjuti, sementara waktu terbuang untuk lead yang tidak akan pernah konversi.

Kesulitan utama: (1) data kotor - duplikat dan nilai kosong; (2) kecocokan dengan Ideal Customer Profile (ICP) sulit dinilai manual; (3) sinyal minat tersebar (perilaku web, isi pesan, sumber lead); (4) skoring manual berbasis poin tidak belajar dari hasil won/lost.

Tujuan: membangun sistem multi-agen yang membersihkan, memperkaya, menilai, dan merekomendasikan tindakan untuk setiap lead, yaitu skor 0-100 (probabilitas konversi) dan kategori hot / warm / cold, sehingga sales fokus pada lead dengan peluang tertinggi.

Pilihan topik: agen 'Lead Qualification Agent' (#33) dan 'Lead Scoring Agent' (#37) pada tab spesifikasi, digabung dengan Lead Enrichment (#14) dan ICP Finder (#11). Topik ini belum diambil kelompok 1-6 (yang mengambil complaint handling, procurement, AI outsourcing, trading Bitcoin, customer service, dan software developer agent).

# 3. Ilustrasi Data dan Perhitungan Komputasi

Data CRM nyata bersifat rahasia, sehingga dipakai data sintetis (seed=42, 2.060 baris mentah termasuk 60 duplikat sengaja; 8% nilai kosong pada employees & title\_level). Label 'converted' dibangkitkan dari fungsi logit tersembunyi yang tidak dilihat agen. Angka hasil karenanya BUKAN bukti performa di dunia nyata; ini bukti bahwa pipeline bekerja dan dapat dibandingkan dengan baseline.

## Contoh 3 lead (fitur mentah + hasil agen ICP-Fit):

| Lead | pricing_views | demo | days_since | icp_fit |
|------|---------------|------|------------|---------|
| A    | 3             | 1    | 5          | 0.911   |
| B    | 0             | 0    | 60         | -0.107  |
| C    | 1             | 0    | 20         | 0.649   |

Langkah 1 - icp\_fit (cosine). Centroid pelanggan won:  $\mu = [0,5; 0,3; 0,1; 0,4; 0,5]$  (logistics, manufacturing, retail, size\_z, title/3). Lead A =  $[1, 0, 0, 0,5, 0,67]$ :  $A \cdot \mu = 0,5 + 0,2 + 0,335 = 1,035$ ;  $\|A\| = 1,303$ ;  $\|\mu\| = 0,872 \rightarrow \cos = 1,035 / (1,303 \times 0,872) = 0.911$ .

Langkah 2 - skoring dengan bobot ilustrasi  $w = [0,9; 1,2; -0,02; 2,0]$ ,  $b = -3,0$ . Lead A:  $z = -3 + 0,9(3) + 1,2(1) - 0,02(5) + 2,0(0,911) = 2.622 \rightarrow p = 1 / (1 + e^{-2.622}) = 0.932 \rightarrow$  skor 93 (hot).

Langkah 3 - umpan balik. Jika A benar-benar konversi ( $y=1$ ):  $\text{loss} = -\ln(0.932) = 0.0704$ ; gradien bobot =  $(p - y) \times x = [-0.204, -0.068, -0.34, -0.062]$ ; dengan  $\eta = 0,1$  bobot menjadi  $[0.92, 1.207, 0.014, 2.006]$  (bobot pricing\_views & demo naik, days\_since menjadi kurang negatif).

## Hasil perhitungan skoring:

| Lead | $z = b + w \cdot x$ | $p = \text{sigma}(z)$ | Skor | Tier |
|------|---------------------|-----------------------|------|------|
| A    | 2.622               | 0.932                 | 93   | hot  |

| Lead | $z = b + w.x$ | $p = \text{sigma}(z)$ | Skor | Tier |
|------|---------------|-----------------------|------|------|
| B    | -4.413        | 0.012                 | 1    | cold |
| C    | -1.202        | 0.231                 | 23   | warm |

**Pipeline penuh dijalankan pada seluruh data sintetis (kode: src/run\_demo.py). Ringkasan keluaran agen:**

- EnrichmentAgent: removed 61 duplicates, imputed 324 missing values
- ICPFitAgent: icp\_fit computed, mean=0.385
- IntentAgent: text\_intent computed, mean=0.178
- ScoringAgent: trained on 1393 leads
- ScoringAgent: tiers {'cold': 1340, 'warm': 463, 'hot': 196}
- ActionAgent: actions assigned {'Add to low-touch newsletter': 1340, 'Nurture: case-study email + retarget': 344, 'Assign to AE: call within 24h': 143, 'Nurture: webinar invite': 119, 'Assign to AE: book demo': 53}

## 4. Rumus Notasi Matematika

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$$

$\mathbf{a}, \mathbf{b}$  = vektor lead & centroid ICP (atau vektor teks);  $\mathbf{a} \cdot \mathbf{b}$  = dot product;  $\|\cdot\|$  = norma Euclid. Dipakai untuk icp\_fit, text\_intent, dan deteksi duplikat (trigram karakter). Rentang -1..1.

$$\text{tfidf}(t, d) = \text{tf}(t, d) \cdot \left( \ln \frac{1 + N}{1 + \text{df}(t)} + 1 \right)$$

$t$  = term;  $d$  = dokumen (pesan lead);  $\text{tf}$  = frekuensi term di  $d$ ;  $N$  = jumlah dokumen;  $\text{df}(t)$  = jumlah dokumen berisi  $t$  (varian smooth scikit-learn).

$$\tilde{x}_j = \frac{x_j - \mu_j}{\sigma_j}$$

$x_j$  = fitur ke- $j$ ;  $\mu_j$ ,  $\sigma_j$  = rata-rata & simpangan baku dari data latih (dihitung hanya pada train agar tidak bocor).

$$z = b + \mathbf{w}^\top \tilde{\mathbf{x}}, \quad p = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$b$  = bias;  $w$  = vektor bobot;  $\tilde{x}$  = fitur terstandarisasi;  $z$  = log-odds;  $\sigma$  = fungsi sigmoid;  $p$  = probabilitas lead konversi.

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^n [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)] + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

$n$  = jumlah lead latih;  $y_i$  in  $\{0,1\}$  = won/lost;  $p_i$  = prediksi;  $\lambda$  = kekuatan regularisasi L2 (0,01).

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{n} \mathbf{X}^\top (\mathbf{p} - \mathbf{y}) + \lambda \mathbf{w}, \quad \mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} \mathcal{L}$$

$\mathbf{X}$  = matriks fitur ( $n \times d$ );  $p, y$  = vektor prediksi & label;  $\eta$  = learning rate (0,3); 1.500 iterasi gradient descent.

$$\text{score} = \text{round}(100p)$$

$$\text{hot: } p \geq 0.5; \quad \text{warm: } 0.2 \leq p < 0.5; \quad \text{cold: } p < 0.2$$

Skor 0-100 adalah probabilitas terkalibrasi (bukan poin sembarang). Ambang 0,5 dan 0,2 disesuaikan dengan base rate konversi ~19%.

$$AUC = P(s^+ > s^-)$$

$$\text{Prec} = \frac{TP}{TP + FP}, \quad \text{Rec} = \frac{TP}{TP + FN}$$

$$\text{Lift}@k = \frac{\text{konversi top } k}{\text{konversi rata rata}}$$

$s^+$  /  $s^-$  = skor lead yang konversi / tidak; TP, FP, FN = true positive, false positive, false negative;  $k$  = 10% lead teratas.

## 5. Tiga Penelitian Serupa (Lead Scoring / Kualifikasi Prospek)

González-Flores, L., Rubiano-Moreno, J., Sosa-Gómez, G. (2025). The relevance of lead prioritization: a B2B lead scoring model based on machine learning. *Frontiers in Artificial Intelligence*. DOI 10.3389/frai.2025.1554325.

Studi kasus perusahaan software B2B (data lead Jan 2020 - Apr 2024); membandingkan 16 algoritma klasifikasi dan melaporkan Gradient Boosting paling unggul. Tautan: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2025.1554325/full>

Wu, M., Andreev, P., Benyoucef, M. (2024). The state of lead scoring models and their impact on sales performance. *Information Technology and Management*, 25(1). DOI 10.1007/s10799-023-00388-w.

Tinjauan pustaka sistematis 44 studi: model tradisional (berbasis pengalaman) vs prediktif (ML), dengan 14 metrik dampak ke kinerja penjualan. Tautan: <https://link.springer.com/article/10.1007/s10799-023-00388-w>

D'Haen, J., Van den Poel, D. (2013). Model-supported business-to-business prospect prediction based on an iterative customer acquisition framework. *Industrial Marketing Management*, 42(4), 544-551.

Kerangka akuisisi pelanggan iteratif untuk memprediksi prospek B2B; dasar pendekatan 'prospect prediction' yang dipakai riset skoring berikutnya.

## 6. Intelligent Agent System

### 6.1 Mengapa multi-agent, bukan single agent?

Single agent cukup untuk fungsi sempit (mis. hanya menghitung skor). Namun alur 'lead mentah -> tindakan sales' melibatkan beberapa kompetensi dan sumber data, jadi dipilih sistem multi-agen (kategori 'Multiple AI Agents' pada Dimensi 1, dengan elemen Agentic pada feedback loop).

| Alasan                   | Penjelasan                                                                                                                                                     |
|--------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Tugas heterogen          | Dedup/imputasi, kemiripan ICP, NLP teks, klasifikasi, dan aturan tindakan memakai teknik berbeda; satu agen monolit akan sulit diuji dan dirawat.              |
| Modularitas & ablation   | Tiap agen dapat diganti/diuji terpisah (mis. ganti Logistic Regression dengan XGBoost tanpa menyentuh agen lain).                                              |
| Pemisahan tanggung jawab | Agen deterministik (Enrichment, Action-rule) terpisah dari agen probabilistik (Scoring) sehingga audit & guardrail jelas - relevan dengan temuan CRMarena-Pro. |
| Skala & paralel          | Intent dan ICP-Fit tidak saling bergantung, dapat berjalan paralel per batch lead; orchestrator mengatur urutan dan retry.                                     |
| Feedback loop            | Orchestrator memantau AUC pada hasil won/lost dan memicu retrain - perilaku agentik (memantau lingkungan, menyesuaikan diri).                                  |

### 6.2 Tiga penelitian yang menggunakan agen cerdas

Huang, K.-H., Prabhakar, A., Thorat, O., et al. (2025). CRMarena-Pro: Holistic Assessment of LLM Agents Across Diverse Business Scenarios and Interactions. arXiv:2505.18878 (Salesforce AI Research).

Benchmark 22 tugas CRM (termasuk lead qualification). Agen LLM terbaik hanya ~58% sukses satu-giliran dan ~35% multi-giliran -> perlu komponen deterministik/ML & guardrail. Tautan: <https://arxiv.org/abs/2505.18878>

Dhanyamraju, H. R., Raghav, L., Lee, A. (2026). Autonomous Event-Driven Multi-Agent Orchestration for Enterprise AI at Scale. arXiv:2606.20058.


Orkestrasi multi-agen event-driven untuk enrichment, pra-kualifikasi, dan penilaian kesiapan lead; dilaporkan mengurangi kerja manual ~70%. Tautan: <https://arxiv.org/abs/2606.20058>

Wu, Q., Bansal, G., Zhang, J., et al. (2023). AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation. arXiv:2308.08155 (Microsoft Research).

Kerangka multi-agen dengan agen tersepeialisasi yang saling berkomunikasi; dasar pola orchestrator + agen peran khusus. Tautan: <https://arxiv.org/abs/2308.08155>

Verifikasi: metadata dua makalah pertama tiap daftar dicek lewat pencarian web pada sesi pengerjaan; D'Haen & Van den Poel (2013) dan AutoGen ditulis dari pengetahuan penulis dan belum dibuka ulang - mohon dicek sebelum dikumpulkan.

## 6.3 Diagram rencana sistem



Alur: lead masuk -> Enrichment -> ICP-Fit -> Intent -> Scoring -> Action -> CRM/Sales. Orchestrator mengatur urutan lewat blackboard bersama; hasil won/lost dikembalikan ke Scoring Agent (feedback loop) untuk retrain.

## 6.4 Komponen internal tiap agen

| Agen             | Input / percept                          | Komponen internal                                                                                    | Output                                        | Metode                           |
|------------------|------------------------------------------|------------------------------------------------------------------------------------------------------|-----------------------------------------------|----------------------------------|
| Enrichment Agent | Lead mentah (nama, perusahaan, atribut)  | Blocking key + TF-IDF trigram karakter, cosine similarity $\geq 0,60$ ; imputasi median per industri | Lead bersih tanpa duplikat, nilai lengkap     | Klasik ML / NLP (bukan DL)       |
| ICP-Fit Agent    | Lead bersih + histori won                | Vektor fitur (one-hot industri, ukuran, jabatan); centroid pelanggan won (dari data latih saja)      | icp_fit in [-1,1]                             | Similarity search (unsupervised) |
| Intent Agent     | Pesan lead, sumber, perilaku web         | TF-IDF uni+bigram vs prototipe 'niat beli'; skor sumber; log ukuran                                  | text_intent, source_score, fitur turunan      | NLP klasik (TF-IDF)              |
| Scoring Agent    | Matriks 10 fitur + label historis        | Standardisasi, Logistic Regression L2 (gradient descent), pemetaan skor & tier                       | p_convert, skor 0-100, tier                   | Supervised ML                    |
| Action Agent     | Tier + sinyal (demo, pricing views)      | Tabel aturan next-best-action; hook opsional LLM untuk draf e-mail                                   | Rekomendasi tindakan + draf e-mail (opsional) | Rule-based (+ LLM opsional)      |
| Orchestrator     | Semua keluaran agen, hasil won/lost baru | Penjadwal urutan, blackboard (State), monitor drift AUC, trigger retrain, log                        | Alur end-to-end & jejak audit                 | Kontrol / orkestrasi             |

## 6.5 AI, ML, atau DL?

Sistem ini memakai kombinasi AI klasik + ML supervised, bukan Deep Learning. Alasan: (1) data tabular berukuran ~2 ribu baris - pada data tabular kecil, model linier/tree biasanya setara atau lebih baik daripada DL; (2) skor harus dapat dijelaskan ke tim sales (bobot per fitur pada gambar bobot), penting untuk kepercayaan dan audit; (3) biaya komputasi rendah, berjalan di CPU dalam detik.




Verifikasi implementasi: model numpy buatan sendiri menghasilkan AUC 0.853 vs LogisticRegression scikit-learn 0.853 pada data uji yang sama.

DL/LLM ditempatkan hanya di tempat yang tepat: penulisan draf e-mail (Action Agent, opsional) dan pengayaan teks bila data pesan bertambah (mis. embedding BERT menggantikan TF-IDF). Rencana tahap berikut: bandingkan dengan Gradient Boosting/XGBoost (sesuai temuan González-Flores et al., 2025).

## 7. Hasil Awal dan Keterbatasan

| Metrik (data uji, n=606)          | Agen (LogReg)        | Baseline poin manual |
|-----------------------------------|----------------------|----------------------|
| AUC                               | 0.853                | 0.814                |
| Lift@10% teratas                  | 3.68x                | 3.59x                |
| Precision / Recall @ $p \geq 0,5$ | 0.73 / 0.38          | -                    |
| Precision / Recall @ $p \geq 0,3$ | 0.56 / 0.57          | -                    |
| Konversi hot / warm / cold        | 72.6% / 32.6% / 6.7% | -                    |

- Pipeline membersihkan 2060 -> 1999 lead (61 duplikat dibuang untuk 60 duplikat yang disisipkan; 324 missing values).
- Lead 'hot' berkonversi 72.6% vs 6.7% untuk 'cold' (rata-rata 19.3%) - tier memisahkan peluang dengan jelas.
- Keterbatasan: data sintetis; recall pada ambang 0,5 rendah (0,38) sehingga ambang perlu disesuaikan dengan kapasitas sales; belum ada uji pada data nyata, dan belum diuji drift.



## 8. Rencana Berikutnya

- Tugas berikutnya: integrasi LLM untuk draf e-mail, perbandingan XGBoost, simulasi drift & retrain otomatis, dashboard ringkas.
- Bila memungkinkan: uji pada dataset lead publik agar hasil tidak bergantung pada data sintetis.

## 9. Tautan Kode

GitHub: <https://github.com/AdityaIKO/Agentic-Enterprise> (folder src/, data/, outputs/, docs/).

Menjalankan: `pip install -r requirements.txt; python src/run_demo.py; python src/make_figures.py`.